内积空间在推荐系统中的应用：协同过滤方法

引言

随着互联网技术的迅猛发展，推荐系统已成为电子商务、视频流媒体等平台的核心。推荐系统通过分析用户历史行为，为用户提供个性化推荐。协同过滤因其简单高效被广泛应用，内积空间为其提供了数学框架。本报告探讨内积空间在协同过滤中的应用，涵盖理论基础、实现方法和实验分析。

一、内积空间的基本概念

内积空间是向量空间的一个扩展，通过引入内积函数为向量赋予了长度和角度的度量。形式上，设 V 是一个**实数域**上的向量空间，内积是一个二元函数: $\mathrm{V} \times \mathrm{V} \to \mathbb{R}$，满足以下性质：

对称性：对于任意向量 $\mathbf{u}, \mathbf{v} \in V$，有 $\langle \mathbf{u}, \mathbf{v} \rangle = \langle \mathbf{v}, \mathbf{u} \rangle$；

线性：对于任意标量$a, b \in \mathbb{R}$和向量$\mathbf{u}, \mathbf{v}, \mathbf{w} \in V$，有$\langle a\mathbf{u} + b\mathbf{w}, \mathbf{v} \rangle = a\langle \mathbf{u}, \mathbf{v} \rangle + b\langle \mathbf{w}, \mathbf{v} \rangle$；

正定性：对于任意向量$\mathbf{u} \in V$，有$\langle \mathbf{u}, \mathbf{u} \rangle \geq 0$，且$\langle \mathbf{u}, \mathbf{u} \rangle = 0$ 当且仅当$\mathbf{u} = \mathbf{0}$。

内积空间允许我们定义向量的范数$|\mathbf{u}| = \sqrt{\langle \mathbf{u}, \mathbf{u} \rangle}$ 和向量之间的夹角 $\cos\theta = \frac{\langle \mathbf{u}, \mathbf{v} \rangle}{|\mathbf{u}||\mathbf{v}|}$ 。在推荐系统中，用户和物品被表示为高维空间中的向量，内积则用于计算它们之间的相似度或预测用户对物品的偏好。

在实验中，余弦相似度通过 surprise 库的 KNNBasic 算法实现，基于内积空间计算用户之间的相似性。

二、协同过滤的原理

协同过滤是一种基于群体智慧的推荐方法，主要分为下面两种类型：

基于用户的协同过滤：通过识别与目标用户相似的其他用户，利用这些相似用户的行为或评分预测目标用户的偏好。

基于物品的协同过滤：通过识别与目标物品相似的其他物品，基于用户对这些相似物品的评分预测用户对目标物品的偏好。

在这两种方法中，相似度的计算是核心步骤，而内积空间为相似度计算提供了理论支持。用户和物品的评分向量在内积空间中通过余弦相似度度量相似性，**实验中采用基于用户的协同过滤。**

三、方法实现

1. 用户-物品评分矩阵

协同过滤的基础是用户-物品评分矩阵 R。该矩阵的行表示用户，列表示物品，矩阵元素r_{ui}表示用户 u 对物品 i 的评分。如果用户未对某物品评分，则该元素为空（即缺失值）。假设有 m 个用户和 n 个物品，则 R 是一个 $\mathrm{m} \times \mathrm{n}$ 的矩阵。

例如，一个简单的评分矩阵可能如下所示：

用户/物品	物品 1	物品 2	物品 3
用户 1	5	3	?
用户 2	4	?	2

用户/物品 物品 1 物品 2 物品 3

用户 3　　?　　4　　5

其中“?”表示缺失值，推荐系统的任务是预测这些缺失值。

2. 基于内积的相似度计算

2.1. 用户相似度

在基于用户的协同过滤中，用户之间的相似度通过评分向量的内积计算。设$\mathbf{r}_u$和$\mathbf{r}_v$分别为用户 u 和用户 v 的评分向量，则它们的内积为：

$$\langle \mathbf{r}u, \mathbf{r}v \rangle = \sum i \in Iuv\, r_{ui} r_{vi}$$

其中I_{uv}是用户 u 和 v 共同评分的物品集合。为了消除评分尺度的差异，通常采用余弦相似度：

$$s_{uv} = \frac{\langle \mathbf{r}_u, \mathbf{r}_v \rangle}{|\mathbf{r}_u||\mathbf{r}_v|}$$

余弦相似度的值范围在[-1, 1]之间，值越大表示用户之间的偏好越相似。

实验中使用 surprise 库的 KNNBasic 算法，基于余弦相似度计算用户相似性。

2.2. 物品相似度

在基于物品的协同过滤中，物品之间的相似度通过物品评分向量的内积计算。设$\mathbf{r}_i$和 $\mathbf{r}_j$分别为物品 i 和物品 j 的评分向量（即矩阵 R 的列向量），则它们的内积为：

$$\langle \mathbf{r}i, \mathbf{r}j \rangle = \sum u \in Uij\, r_{ui} r_{uj}$$

其中U_{ij}是同时对物品 i 和 j 评分的用户集合。同样，余弦相似度为：

$$s_{ij} = \frac{\langle \mathbf{r}_i, \mathbf{r}_j \rangle}{|\mathbf{r}_i||\mathbf{r}_j|}$$

注：在本次实验中未实现基于物品的协同过滤，仅作为理论补充。

3. 预测用户评分

预测用户 u 对物品 i 的评分$\hat{r}_{ui}$可通过加权平均方法计算：

$$\hat{r}ui = \bar{r}u + \frac{\sum v \in N(u)\, suv(r_{vi} - \bar{r}v)}{\sum v \in N(u)\, |s_{uv}|}$$

其中：

$\bar{r}_u$是用户 u 的平均评分；

$N(u)$是与用户 u 相似的前 k 个用户集合；

s_{uv}是用户 u 和 v 的相似度；

$r_{vi} - \bar{r}_v$表示用户 v 对物品 i 的评分偏差。

实验中通过 surprise 的 KNNBasic 实现此方法。

4.处理缺失值

评分矩阵（R）通常是稀疏的，实验中使用 surprise 库的默认处理方式，通过忽略缺失值直接计算余弦相似度。

四、实验分析

为了验证内积空间在协同过滤中的应用效果，我们基于 Movielens 数据集进行了实验。

1. 数据集描述

实验使用 MovieLens 小数据集（ml-latest-small），包含 600 个用户对 9000 部电影的 100000 条评分记录。具体有下面两个文件：

ratings.csv：包含用户 ID、电影 ID 和评分（0.5 到 5.0）。

movies.csv：包含电影 ID 和标题。

数据来源于 GroupLens 研究小组（https://grouplens.org/datasets/movielens/）。

图 1 数据集来源

2. 算法流程

使用 pandas 加载 ratings.csv 和 movies.csv，通过 os.path.join 确保路径正确。

将数据转换为 surprise 格式，划分 80% 训练集和 20% 测试集。

使用余弦相似度训练用户-用户协同过滤模型。

在测试集上评估模型，计算 RMSE。

$$\mathrm{RMSE} = \sqrt{\frac{1}{N}\sum_{(u,i)}(r_{ui} - \hat{r}_{ui})^2}$$

其中$\hat{r}_{ui}$是预测评分，r_{ui}是实际评分，N 是测试集评分总数。

为指定用户生成前 10 部电影推荐。

3. 实验结果

RMSE：0.9780，表明模型预测评分与实际评分的平均误差较小，模型性能良好。

推荐示例（用户 ID 1 的前 10 项推荐）：

he Usual Suspects (1995): 4.43

Indiana Jones and the Last Crusade (1989): 4.31

Gladiator (2000): 4.23

Lock, Stock & Two Smoking Barrels (1998): 4.14

Groundhog Day (1993): 4.14

Back to the Future (1985): 4.11

Run Lola Run (Lola rennt) (1998): 4.09

Psycho (1960): 4.08

Monty Python's Life of Brian (1979): 4.05

American Beauty (1999): 4.04

```
"D:\anaconda\envs\machine learning test\python.exe" "D:\pycharm community\machine learning test\recommendation_system.py"
Computing the cosine similarity matrix...
Done computing similarity matrix.
RMSE: 0.9780
RMSE: 0.9779817333167938
用户 1 的前 10 项推荐:
Usual Suspects, The (1995): 4.43
Indiana Jones and the Last Crusade (1989): 4.31
Gladiator (2000): 4.23
Lock, Stock & Two Smoking Barrels (1998): 4.14
Groundhog Day (1993): 4.14
Back to the Future (1985): 4.11
Run Lola Run (Lola rennt) (1998): 4.09
Psycho (1960): 4.08
Monty Python's Life of Brian (1979): 4.05
American Beauty (1999): 4.04

进程已结束,退出代码0
```

图 2 运行结果

五、结论

通过内积空间的余弦相似度，推荐系统成功为用户生成个性化电影推荐。RMSE 值为 0.9780 表明模型具有较好的预测能力。代码通过路径检查和动态路径构建解决了文件加载问题，确保稳定运行。内积空间的数学特性在余弦相似度中得到充分体现，为协同过滤提供了理论支持。

参考文献

GroupLens. MovieLens 小数据集. https://grouplens.org/datasets/movielens/

Koren, Y., Bell, R., & Volinsky, C. (2009). Matrix Factorization Techniques for Recommender Systems. Computer, 42(8), 30-37.